EXCELCOMPARE — BỘ TÀI LIỆU SẢN PHẨM & KỸ THUẬT

PRD • SRS • Kiến trúc • Data Types • OCR • Security • QA • DevOps • Operations

Bản thiết kế tham chiếu — Android/Kotlin

22 tháng 10 năm 2026

Trạng thái: 1.0-DESIGN / Proposed baseline. Tài liệu này là đặc tả hướng production, **chưa phải** chứng nhận ứng dụng đã được triển khai, kiểm thử hoặc có hạ tầng đang vận hành.

Phân định: Ràng buộc gốc: so sánh 2 file Excel, thống kê giống và khác, chỉ vị trí sai khác, đọc nội dung từ ảnh, đóng gói cài đặt. Tất cả hỗ trợ format mới, chính sách semantic, cloud OCR và vận hành là phần mở rộng được đề xuất.

DANH MỤC TÀI LIỆU

1. Product Brief và quyết định phạm vi
2. PRD - Yêu cầu sản phẩm và hành trình người dùng
3. SRS - Chức năng và quy tắc nghiệp vụ
4. Định dạng tệp, MIME, phạm vi adapter và giới hạn
5. DataType, chuẩn hóa ngữ nghĩa và policy engine
6. Data contracts, schema và provenance
7. Thiết kế kiến trúc, module và công nghệ
8. Đặc tả OCR: API, kiểm soát lỗi và privacy
9. NFR, hiệu năng, reliability, accessibility
10. Threat model, bảo mật và quản trị dữ liệu
11. Test Strategy, test cases và quality gates
12. Build, CI/CD, phát hành và bảo trì
13. Runbook vận hành, bảo trì và xử lý sự cố
14. Lộ trình, nhân sự, chi phí và risk register
15. Architecture Decision Records và vấn đề còn mở
16. Nguồn kỹ thuật, thuật ngữ, giới hạn xác minh

Tài liệu đi kèm: ví dụ `comparison_policy.example.json`, `report_example.json`, `acceptance_cases.json`, sơ đồ kiến trúc và README.

01. Product Brief và quyết định phạm vi

Mã dự án: EXC; **tên làm việc:** ExcelCompare; **bản tài liệu:** 1.0-DESIGN; **ngày:** 22/10/2026; **nền tảng mục tiêu:** Android/Kotlin; **trạng thái:** baseline thiết kế, chưa chứng nhận production.

1.1. Tuyên bố vấn đề

Nhiều hệ thống xuất báo cáo dạng bảng tính nhưng cùng dữ liệu có thể khác tên cột, thứ tự hàng, kiểu lưu trữ, cách viết ngày/số, công thức và metadata. So sánh hai tệp bằng cách nhìn trực tiếp hoặc so từng tọa độ ô gây báo sai khác giả và bỏ sót sai khác nghiệp vụ. Ảnh chụp là nguồn đầu vào khó hơn vì chỉ giữ lại biểu diễn trực quan và không thể truy cập các thuộc tính ẩn trong workbook.

1.2. Giá trị sản phẩm

Ứng dụng tiếp nhận hai nguồn dạng bảng, ánh xạ schema, xác định định danh hàng, chuẩn hóa theo **quy tắc công khai**, đưa ra kết luận có thể truy vết (*exact / equivalent / different / unresolved*), xem chi tiết ô/bản ghi khác biệt và xuất báo cáo kiểm toán. Không thay đổi dữ liệu nguồn.

1.3. Người dùng mục tiêu và các trường hợp sử dụng

Người dùng	Nhu cầu	Ưu tiên
Sinh viên/kế toán/nhân sự	So danh sách, điểm số, công nợ, kiểm kê giữa hai lần xuất	P0
Nhân viên kiểm thử dữ liệu	So đầu ra của hai hệ thống sau migrate	P0
Quản trị dữ liệu	Ánh xạ schema, audit, quy tắc chuẩn hóa	P1
Người dùng chỉ có ảnh chụp	OCR bảng đơn giản, hiệu chỉnh rồi so	P2

1.4. In scope / out of scope

P0 - MVP: Android offline; import XLSX/CSV/TSV/JSON dạng bản ghi theo adapter; xem preview, chọn sheet/table, header row; mapping cột thủ công; xác định key đơn/ghép; chuẩn hóa text/decimal/date/boolean/identifier/percentage; đối chiếu record; xuất CSV/XLSX báo cáo đơn giản an toàn; lưu cấu hình và lịch sử so sánh có kiểm soát.

P1: XLS legacy theo proof-of-concept, xlsm chỉ đọc dữ liệu và không chạy macro, ODS adapter riêng, metadata/công thức ở chế độ báo cáo, gợi ý mapping an toàn, xử lý dữ liệu lớn streaming, quy tắc tái sử dụng.

P2: OCR ML Kit với xác nhận ô; cloud layout OCR opt-in; XLSB/PDF/XML/HTML/JSONL; tích hợp hệ thống ngoài; sync đa thiết bị.

Không cam kết: mọi công thức Excel tái tính được; suy luận đúng 100% schema/locale; khôi phục macro; ảnh OCR có metadata Excel; tự động sửa file gốc; phát hiện gian lận doanh nghiệp chỉ bằng sự khác biệt.

1.5. Chỉ số thành công và ranh giới trách nhiệm

Nhóm	Chỉ số đề xuất (chưa đo)	Điều kiện nghiệm thu
An toàn dữ liệu	0 lần ghi vào nguồn; 0 nội dung ô trong telemetry	kiểm thử có chứng cứ
Độ đúng	100% các quy tắc chuẩn hóa có unit test và golden fixture	không tự tương đương khi ambiguous
Truy vết	100% difference có source coordinate + rule version hoặc lý do missing	review report
Ổn định	Không crash/OOM trên bộ stress đã chốt cho thiết bị tham chiếu	benchmark thực nghiệm
Định lượng	Có precision, recall, unresolved rate, elapsed time, peak memory	công bố số đo kèm dữ liệu và cấu hình

Quyết định sản phẩm: 'production-grade specification' khác 'production-qualified product'. Các SLO sẽ chỉ được cam kết sau khi đo trên thiết bị và corpus thực tế.

02. PRD - Yêu cầu sản phẩm và hành trình người dùng

2.1. Jobs-to-be-done

Khi nhận hai bản báo cáo từ nguồn khác nhau, người dùng muốn thấy bản ghi nào thiếu/thừa/thay đổi, tránh báo sai do định dạng khác nhau, biết căn cứ của kết luận và xuất được biên bản có thể xác minh lại.

2.2. User stories (ưu tiên MoSCoW)

ID	User story / tiêu chí chấp nhận	Mức
US-01	Chọn hai tệp bằng Android SAF; hiển thị tên, hash, dung lượng, cảnh báo nguồn	Must
US-02	Tự nhận định dạng qua signature/MIME/content, không tin đuôi file	Must
US-03	Preview 50-100 hàng đầu, lọc sheet/table, chọn hàng header	Must
US-04	Mapping cột A:B, xác nhận cột khóa, cảnh báo key duplicate/null	Must
US-05	Phân loại EXACT/EQUIVALENT/DIFFERENT/UNRESOLVED và ghi lý do	Must
US-06	Bật/tắt chuẩn hóa từng field; xem giá trị raw/typed/normalized	Must
US-07	Xem summary + filter + chi tiết tọa độ ô hai phía	Must
US-08	Xuất report có dữ liệu kiểm toán, không làm thay đổi nguồn	Must
US-09	Hủy an toàn và khôi phục session sau lỗi/đứt tác vụ	Should
US-10	So sánh công thức, style, metadata theo tùy chọn	Should
US-11	OCR ảnh bảng → hiệu chỉnh preview → xác nhận rồi so	Could
US-12	Đề xuất map bằng heuristics, nhưng buộc xác nhận khi mơ hồ	Could

2.3. User flow

1. Dashboard → ‘So sánh mới’. 2. Chọn A, B (SAF). 3. Preflight: file hợp lệ, dung lượng, quyền, bảo vệ bằng mật khẩu. 4. Chọn sheet/table + header. 5. Mapping fields + key + loại so. 6. Chọn policy datatype/locale/tolerance. 7. Review cấu hình. 8. Job tiến độ/phân trang + hủy. 9. Báo cáo 4 trạng thái & structural differences. 10. Export/Share/Delete session.

2.4. Các màn hình

Screen	Dữ liệu/chức năng	Edge UX
Home	lịch sử gần đây, tạo phiên, quyền riêng tư	empty state
Import	2 nguồn, kiểm tra khả năng đọc, nguồn truy cập	permission revoked/unsupported
Sheet Preview	grid ảo hóa, dropdown sheet, header preview	rất nhiều cột/cell merge
Mapping	schema A/B, confidence gợi ý, key selector	duplicate, missing, ambiguous
Policy	datatype ngữ nghĩa, locale, null, tolerance, alias	chỉ đổi policy có version mới

Screen	Dữ liệu/chức năng	Edge UX
Compare	thanh tiến độ, số bản ghi, cancel, error	app background/process death
Results	dashboard summary, tabs rows/fields/values/meta	zero diff vs unresolved
Difference Detail	A/B raw typed canonical, location, rule, explanation	OCR thiếu tin cậy
Export	CSV/XLSX/JSON, anonymize, location SAF	CSV injection
OCR Confirm	hình gốc + overlay bounding boxes + editable grid	mất cột/ô gộp

2.5. Các nguyên tắc UX bắt buộc

- Không dùng màu duy nhất để truyền trạng thái; có biểu tượng/chữ.
- Hiển thị rõ `không thể kết luận` khác `không khác`.
- Khi dự đoán mapping hoặc datatype, công bố confidence, cho sửa và xem trước tác động.
- Chỉ tệp do người dùng chọn được đọc; không yêu cầu quyền quản lý toàn bộ bộ nhớ.
- Không quảng cáo '100% chính xác' cho OCR hay semantic inference.

03. SRS - Chức năng và quy tắc nghiệp vụ

3.1. Ma trận chức năng

ID	Requirement	Logic, đầu ra và tiêu chí chấp nhận
FR-001	Import & detect format	content sniffing, extension chỉ gợi ý; báo mismatch, không thực thi active content
FR-002	Select source scope	workbook/sheet/range hoặc table; nguồn text 1 bảng mặc định
FR-003	Extract provenance	giá trị nguồn, kiểu, display text, formula, original coordinate
FR-004	Profile fields	null rate, inferred dtype, distinct, sample, collision warning
FR-005	Align schema	mapping 1:1 mặc định, mapping 1:n là biến đổi rõ ràng; ghi config
FR-006	Key match	unique key / composite key; duplicate được đưa vào tập lỗi
FR-007	Compare records	row added/removed/updated, move chỉ là thay đổi vị trí
FR-008	Exact compare	so typed raw theo chính sách; phân biệt blank/null/zero
FR-009	Semantic compare	canonicalize theo field rule; xuất evidence transform
FR-010	Compare formulas	so expression, cached values, annotate stale/unsupported
FR-011	Compare metadata	report metadata tách riêng, không trộn cell similarity
FR-012	OCR import	text + geometry; tái dựng table; bắt buộc manual confirmation
FR-013	Export report	summary, detailed diff, manifest, policy/version, unresolved
FR-014	Re-run	cùng input hash + config + engine version phải cho output deterministic

ID	Requirement	Logic, đầu ra và tiêu chí chấp nhận
FR-015	Lifecycle	cancellation, retry theo job state, cleanup temp

3.2. Kế toán số lượng và thống kê

Các trạng thái chính **loại trừ nhau** ở đơn vị so sánh 'matched cell pair': `EXACT`, `EQUIVALENT`, `DIFFERENT`, `UNRESOLVED`. `TYPE_CHANGED`, `FORMULA_CHANGED`, `STYLE_CHANGED`, `OCR_REVIEWED` là flags độc lập.

`exact_rate = exact_pairs / compared_matched_pairs`. `semantic_agreement_rate = (exact + equivalent) / compared_matched_pairs`; mẫu số gồm unresolved để không làm đẹp chỉ số. Bản ghi và cột unmatched báo độc lập; tổng kết không cộng trộn đơn vị khác nhau (cells + rows + sheets).

3.3. Phân loại sai khác và precedence

Mã	Định nghĩa	Xử lý
SHEET_ADDED / REMOVED	Sheet chỉ ở một file	structural diff
FIELD_ADDED / REMOVED	Cột chưa map	schema diff
KEY_DUPLICATE	khóa không duy nhất	unresolved alignment, không gán tùy tiện
ROW_ADDED / REMOVED	Không có matched key	record diff
VALUE_CHANGED	hai canonical typed values không bằng	substantive diff
TYPE_CHANGED	raw storage type thay đổi	flag, có thể semantic match
EQUIVALENT_REPRESENTATION	raw khác nhưng canonical bằng	equivalent + rule id
NULL_MISMATCH	blank/null/empty/zero khác policy	diff hoặc unresolved
FORMULA_CHANGED	biểu thức công thức thay đổi	flag tùy mode
METADATA_CHANGED	document metadata khác	metadata report riêng
OCR_UNCERTAIN	OCR chưa được xác nhận hoặc vùng tin cậy thấp	unresolved, không tự xác nhận

3.4. Matching modes

1. **POSITION:** đồng vị trí hàng/cột; hữu ích khi cấu trúc cố định, không dùng để suy luận 'row changed' khi thứ tự đảo.
2. **KEY:** join theo khóa đơn/ghép đã canonicalize bằng **quy tắc định danh nghiêm ngặt**, không dùng approximate string similarity để nối tự động.
3. **MULTISET:** không có key; đối chiếu theo multiset của dấu vân tay bản ghi; báo unpaired rows và duplicate counts, không suy diễn record identity.
4. **ORDERED_SEQUENCE:** so theo thứ tự để phát hiện chèn/xóa; dùng diff algorithm có giới hạn hiệu năng, không áp dụng mặc định.

3.5. Invariants

- Không sửa workbook nguồn trong bất kỳ giai đoạn nào.
- Kết luận `EQUIVALENT` phải có `rule_id` và canonical values, không chỉ là similarity score.
- Bất kỳ parse/mapping/locale ambiguity trọng yếu đều trở thành `UNRESOLVED` hoặc phải được người dùng xác nhận.
- Mỗi difference có 2 provenance paths, hoặc `null` có lý do rõ (row/file missing).
- Không so sánh numeric mã định danh chỉ vì trông giống số.

04. Định dạng tệp, MIME, phạm vi adapter và giới hạn

4.1. Ma trận đầu vào (tính năng thiết kế, không phải hỗ trợ đã triển khai)

Format	Pha	Parser/adapter đề xuất	Hạn chế/gate
`.xlsx` OOXML	P0	OOXML SAX/event reader hoặc Apache POI XSSF event	thử nghiệm Android compatibility, zipbomb/size limits
`.csv`	P0	Apache Commons CSV hoặc RFC 4180 parser	charset/locale/delimiter/ quotes/BOM phải xác nhận
`.tsv`	P0	text delimited adapter	escaping/quotes/encoding, row length
`.json`	P0	kotlinx.serialization streaming JSON arrays/objects	records path selector, nested arrays not flattened silently
`.jsonl` / `.ndjson`	P1	line streaming JSON decoder	lỗi 1 dòng không được nuốt, schema drift
`.xls`	P1	POI HSSF/event (PoC trước khi cam kết Android)	giới hạn cũ, formula/chart/metadata
`.xlsm`	P1	XLSX-compatible read only, không execute VBA	không ghi đè/không bảo toàn macro khi export
`.ods`	P1	ODF/OpenDocument parser adapter	kiểm tra implementation Android, merged cells, formula semantics
`.xml`	P2	secure streaming XML (StAX/SAX) + user-selected XPath-like mapping	entity expansion/XXE protection; không suy luận bảng tùy ý
`.html` table	P2	Jsoup table adapter, sanitizer	row/col spans, nested tables, script ignored
`.xlsb`	P2	POI XSSFB event read hoặc backend adapter	chỉ bật khi PoC có corpus và benchmark
`.pdf`	P2	parser + table layout/OCR pipeline	metadata/công thức Excel **không thể** khôi phục
`.png/.jpg/.webp/.heic`	P2	Android decoder + ML Kit OCR + table reconstruction	hình ảnh ≠ workbook; confidence, manual review
`.parquet/.arrow`	Out by default	optional desktop/server adapter	phụ thuộc native/lib, không ép vào APK cơ bản
`.zip` nhiều file	Out by default	explicit archive import future	nested bomb/path traversal risk
Google Sheets URL	Out by default	user export to XLSX/CSV, OAuth integration future	không scraping màn hình, không bắt buộc network

4.2. MIME và magic bytes

Kiểm tra signature + structural integrity + MIME provider + extension; mọi bất đồng phải hiển thị. OOXML có ZIP signature nhưng vẫn phải xác nhận `[Content_Types].xml` và workbook relationships. Legacy XLS có OLE Compound File signature. CSV/TSV/JSON text không có magic cố định: xác định BOM/charset, sampling, parser validation, UTF-8 default có user override.

Không đọc 'file `.xlsx`' bằng cách tin phần mở rộng duy nhất. Không thực thi macro, công thức bên ngoài, embedded scripts hoặc external links. Không tự download linked resources.

4.3. Nguồn có kiểu dữ liệu khác nhau

CSV/TSV: giá trị ban đầu được coi là TEXT và kiểu mục tiêu do schema inference + policy, không xem trường `00123` thành integer nếu chưa được chấp thuận. JSON: bảo tồn JSON number/string/boolean/null và lexical representation số khi có thể. XLSX: bảo tồn raw stored type, displayed value và format code. OCR: TEXT + geometric positions + confidence (nếu available), chỉ nâng lên canonical typed sau xác nhận.

4.4. Output formats

- `report.json`: máy đọc, đầy đủ schema, status, provenance, rules, manifest; format chuẩn và có `schema_version`.
- `report.csv`: bảng diff phẳng, encode UTF-8 BOM tùy cấu hình, bảo vệ formula injection; metadata phức tạp báo sang JSON riêng.
- `report.xlsx`: summary sheet / differences sheet / unresolved sheet / manifest sheet; tất cả dữ liệu chưa tin cậy được ghi như **string cell**, không ghi formula executable.
- `report.pdf`: human readable tùy chọn khi đã có output template và kiểm thử layout.

4.5. Định nghĩa hỗ trợ theo mức

`FULL_SEMANTIC`: parser có raw type, sheet, formula và coordinate đủ cho chế độ đó; `TABULAR_VALUES_ONLY`: chỉ giá trị bảng; `OCR_REVIEW_REQUIRED`: phải xác nhận; `UNSUPPORTED`: từ chối an toàn. Một format không đồng nghĩa hỗ trợ tất cả cấp so sánh.

05. DataType, chuẩn hóa ngữ nghĩa và policy engine

5.1. Các tầng type

1. **Physical/storage dtype:** OOXML `s/n/b/e/inlineStr`, JSON native type, CSV textual, formula cell, OCR text.
2. **Logical dtype:** `string`, `int64`, `decimal`, `date`, `datetime`, `bool`, `null`, `array`, `object`.
3. **Semantic dtype:** `identifier`, `person_name`, `currency`, `percentage`, `unit_quantity`, `postal_code`, `phone`, `email`, `timezone_datetime`, `enum`.
4. **Normalization profile:** locale, timezone, trim, Unicode normalization, case, allowed aliases, numeric rounding/tolerance, null sentinels.

Không áp dụng một bộ cast toàn cục. Dtype inference chỉ là suggestion; policy xác nhận quyết định.

5.2. Bảng chiến lược

Semantic dtype	Canonical	Quy tắc / cảnh báo
identifier	Unicode NFC string	preserve leading zeros, case theo field, no numeric cast
free_text	NFC string	trim outer whitespace optional; không bỏ dấu mặc định
person_name	NFC string	trim/multiple whitespace optional; bỏ dấu chỉ gợi ý, không tự match
integer	arbitrary precision integer	parse locale; decimal fraction không tự truncate
decimal	`BigDecimal` + scale policy	dấu thập phân locale, no binary float equality
money	ISO currency + BigDecimal	không so nếu đơn vị tiền khác mà thiếu FX/cùng thời điểm

Semantic dtype	Canonical	Quy tắc / cảnh báo
percentage	dimensionless decimal	`'10%' → 0.10` chỉ khi field có % semantics
boolean	enum {true,false,null}	alias dictionary field-specific (Có/Không/1/0)
date	`LocalDate` ISO	định dạng input và Excel 1900/1904 date system
datetime	`Instant` hoặc local datetime tagged zone	không bỏ timezone; DST ambiguity unresolved
phone	E.164 **nếu** có region rule	giữ string gốc; mã vùng/ngữ cảnh thiếu unresolved
email	string domain normalization policy	local part case policy; không tự lowercase toàn bộ
enum	stable code	dictionary versioned, many-to-one mappings review
unit_quantity	value + UCUM-like unit	quy đổi chỉ khi loại đại lượng tương thích
blank/null/empty	tagged union	0 ≠ null; Excel empty string ≠ missing by default

5.3. Các ca nguy hiểm

- `00123` vs `123` là **DIFFERENT** nếu field là mã, mặc dù parse numeric bằng nhau.
- `1,234` không có locale là **UNRESOLVED**; theo en-US là 1234, vi-VN có thể là 1.234.
- `0.1` vs `10%` chỉ EQUIVALENT nếu field là tỷ lệ và representation scale đã định.
- `2026-03-01T00:30+07:00` vs `2026-02-28T17:30Z` có cùng instant, nhưng khác local calendar day; profile quyết định.
- `TRUE` vs `1` chỉ EQUIVALENT nếu boolean mapping được cho phép.
- `8.5` vs `8,5` chỉ so Decimal tương đương khi quy tắc decimal separator tường minh.
- `Nguyen An` vs `Nguyễn An` không tự coi bằng nếu họ tên pháp lý, vì khác ký tự.
- BigDecimal `0.300` vs `0.3`: bằng theo giá trị nếu policy ignore scale, khác theo biểu diễn nếu strict formatting mode.
- `null`, missing cell, blank, empty string, `N/A` và zero là những trạng thái khác nhau trừ khi null mapping cụ thể.

5.4. Pipeline canonicalization

`RawCell -> Detect original_type -> Validate field policy -> Parse with locale -> Normalize typed value -> Attach transformation trace -> Compare`; mọi lỗi parse trả `UNRESOLVED + reason_code`. Không dùng `Double` để so tiền.

5.5. Matching và độ đúng

- Align field thủ công, tên giống/gần nhau là gợi ý chứ không phải sự thật.
- Key matching dùng strict canonical identifier; duplicate key tạo bucket unresolved thay vì chọn hàng ngẫu nhiên.
- Compound key đóng gói có length prefix hoặc typed tuple để tránh collision (`('ab','c')` khác `('a','bc')`).
- Stable hash (SHA-256) dùng tối ưu tra cứu; **hash match không đủ** để đồng nhất typed semantics khi serializer/rule khác phiên bản.
- Exactness ưu tiên hơn fuzzy matching; fuzzy scores chỉ cho ứng viên review.

5.6. Thuật toán quy mô lớn

Xây map `key -> row reference` với streamed chunks khi có unique key, so typed normalized cells khi match. Khi RAM thấp, phân vùng theo stable hash xuống encrypted temporary storage và sort-merge, hoặc embedded SQLite index +

disk. Độ phức tạp trung bình cho hash-join là O(n+m), memory O(min(n,m)) nếu map một phía; sort-merge O(n log n + m log m) nếu chưa sắp xếp. Yêu cầu thực nghiệm tránh khẳng định thời gian cố định.

06. Data contracts, schema và provenance

6.1. Entities

Entity	Các trường trọng yếu	Ý nghĩa / constraint
`ComparisonSession`	id, created_at, engine_version, status, policy_digest	lineage và trạng thái
`InputArtifact`	id, uri_hint, file_name, detected_format, sha256, size, selected_scope	không lưu URI public vô thời hạn
`SourceTable`	id, artifact_id, sheet_name, row_count, column_count, header_row	phạm vi xử lý
`SourceCell`	table_id, row, col, raw_type, raw_value, display, formula	không ghi log/telemetry
`FieldMapping`	source_field_a/b, semantic_type, normalization_policy	1-to-1 mặc định
`RecordPair`	key, row_ref_a, row_ref_b, match_mode, status	unique/reference
`Difference`	id, category, severity, field, refs, raw/normalized, rule_id, reason	audit trail
`OCRToken`	text, polygon, source_image, confidence_optional	geometry và review
`ReportManifest`	schema_version, source_hashes, policy_digest, engine, counts	reproducibility

6.2. Versioning

- Dùng SemVer với **engine** và **report schema** độc lập (`engine=1.0.0`, `schema=1`).
- Stable canonical serialization: field order deterministic, UTC timestamps với nguồn timezone, decimal canonical string.
- `policy_digest = SHA-256(canonical_policy_json)`; report kết quả phải chứa snapshot policy hoặc reference kèm hash.
- `source_sha256` chỉ nhằm chứng minh cùng byte tệp, không khẳng định nội dung nghiệp vụ giống nhau.
- Room migrations forward-only, backup/restore có sơ đồ rõ; không xóa database sản phẩm khi migration thất bại.

6.3. Output JSON contract

`ComparisonReport` có `source_a`, `source_b`, `mapping`, `policy`, `summary`, `schema_differences`, `record_differences`, `cell_differences`, `unresolved`, `warnings`, `generated_at`. Cả `source_location` và `comparison_location` phải có; tọa độ OCR là pixel polygon thay vì địa chỉ ô Excel gốc.

6.4. Referential integrity

`Difference` tham chiếu tới `RecordPair` khi có match; `source_ref` dạng discriminated union `{type:excel, sheet, address}` / `{type:csv, line, field}` / `{type:json, pointer}` / `{type:ocr, page, polygon}`. Không giả lập `Sheet1!A1` cho dữ liệu vốn là JSON/PDF.

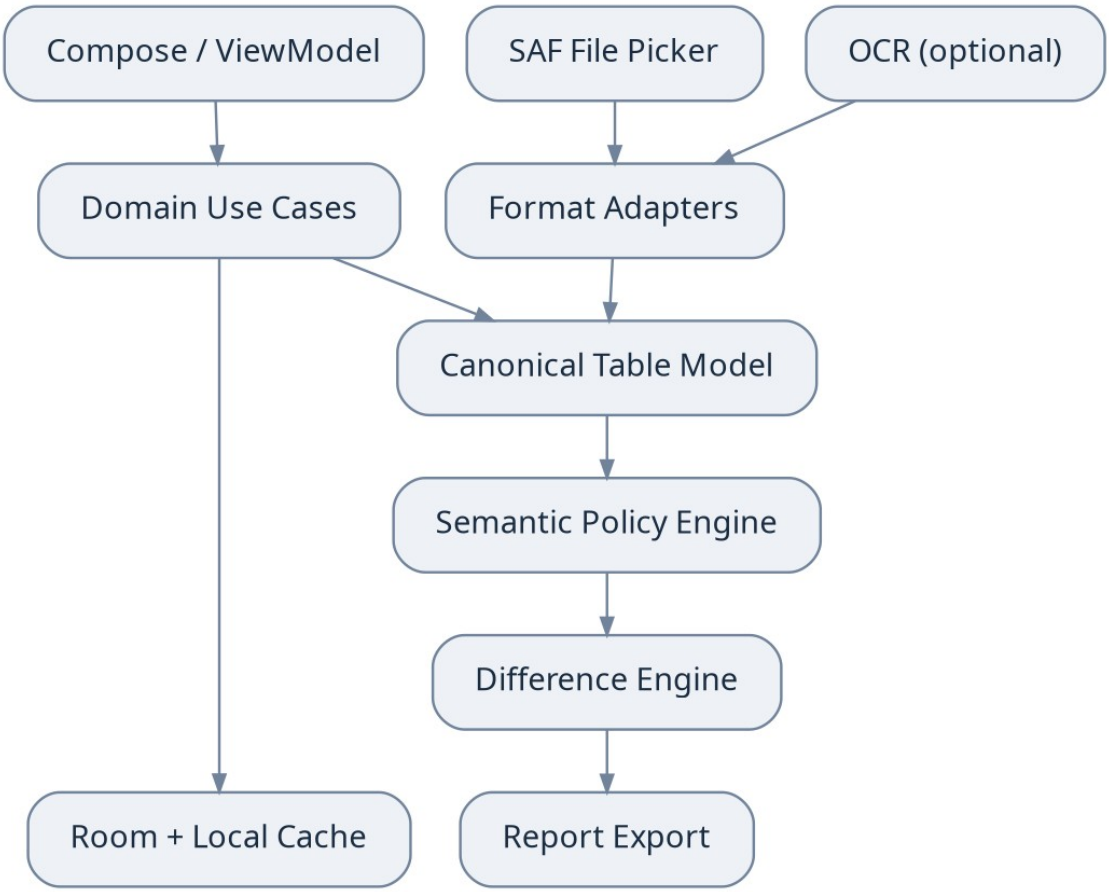
6.5. Các trường tuyệt đối không ghi telemetry

Nội dung cell raw/canonical, tên cá nhân, danh sách định danh, full path file, file URI, ảnh OCR gốc, access tokens, ảnh bảng. Cho phép metric tổng hợp như `duration_ms`, `format_type`, `row_count_bucket`, `error_code` với consent và chống tái nhận diện.

07. Thiết kế kiến trúc, module và công nghệ

7.1. Kiến trúc baseline

Android-first offline-first, Clean Architecture / ports-adapters đơn giản: Presentation (Compose + ViewModel) → Domain (UseCases + policies) → Data (Adapters + repositories + Room). Không đặt logic normalize vào UI; engine là Kotlin/JVM thuần để có thể chạy unit test không Android và tái sử dụng trên server/desktop tương lai.



Sơ đồ kiến trúc

7.2. Module/repository layout

```
excelcompare/
  app/                    # Android manifest, Compose navigation, DI
  core/model/             # immutable canonical domain types
  core/compare/           # matching, normalization, diff, explanations
  core/policy/            # policy validator, parser profiles, versions
  core/storage/           # local cache, Room, lifecycle
  feature/import/         # picker, sniffer, preview
  feature/mapping/        # field/key mapping UX
  feature/results/        # report query and filters
```

```
feature/ocr/            # optional on-device OCR + review
adapter/xlsx/           # streaming OOXML read adapter
adapter/delimited/      # CSV/TSV import/export
adapter/json/           # JSON/JSONL table adapter
adapter/legacy-xls/     # optional, after Android proof of concept
adapter/ods/            # optional independent parser
export/report/          # report JSON/CSV/XLSX
benchmark/              # device benchmarks and fuzz corpus
docs/                   # ADRs, policies, operational runbooks
```

7.3. Công nghệ và vai trò - dùng phiên bản qua version catalog khóa tại thời điểm bắt đầu triển khai

Lớp	Công nghệ	Vai trò / quyết định
Language/Build	Kotlin, Android Gradle Plugin, Gradle Kotlin DSL, JDK theo AGP	compile, tests, build; pin versions sau compatibility test
UI	Jetpack Compose, Material 3, Navigation	màn hình responsive; StateFlow one-way flow
Architecture	ViewModel, Coroutines, Flow, Hilt hoặc Koin (chọn một)	job/state/dependency injection
Local metadata	Room; Proto DataStore	sessions, policy, diff index và setting
Import	Android Storage Access Framework / ContentResolver	scoped read input, no broad storage permission
XLSX	Apache POI event API nếu chạy được trên Android; thay thế: OOXML SAX secure custom adapter	tránh memory bloat; require device PoC
CSV	Apache Commons CSV hoặc parser RFC4180	deterministic delim/escaping
JSON	kotlinx.serialization / streaming JsonReader	JSON arrays + JSONL
OCR	Google ML Kit Text Recognition v2 bundled	on-device tiếng Việt; layout reconstruct riêng
Layout OCR Cloud	Azure Document Intelligence `prebuilt-layout` hoặc Google Document AI	optional service side, opt-in consent + proxy
Imaging	Android Bitmap/ExifInterface; OpenCV optional	crop, rotate, deskew; no AI training mandatory
Security	Android Keystore, encrypted application storage based on threat model	secrets/at rest; network TLS for optional API
Observability	structured local logs without PII; optional crash service with consent	non-sensitive telemetry, error aggregation
QA	JUnit, Kotest optional, instrumented tests, Compose UI tests, Macrobenchmark	correctness/perf/regr
CI/CD	GitHub Actions/Gradle, dependency checks, lint, SBOM, Android signing	controlled releases

Important integration risk: Apache POI là thư viện Java, không thể mặc định mọi artifact XSSF/HSSF chạy ổn định trên mọi Android API/ABI. Cần PoC kiểm chứng minSdk, DEX footprint, dependency conflict, font APIs, memory, reads thực tế. Không ép POI usermodel vào RAM mobile cho workbook lớn.

7.4. Dependency rules

`app -> feature -> domain interfaces <- adapters`; domain không import `android.*`, `org.apache.poi.*`, OCR SDK hoặc `androidx.room.*`. Format adapters tuân thủ `TableReader` contract: `sniff, inspect, open(scope), rows(): Flow<Row>, close`, versioned capabilities, cancel-friendly.

7.5. Policy update impact

Chỉnh locale/key/mapping có thể làm thay đổi toàn bộ kết quả, do đó phải invalidating diff cache, tăng `config_revision`, lưu prior report for history nhưng không giả là cùng phiên so sánh.

08. Đặc tả OCR: API, kiểm soát lỗi và privacy

8.1. Chế độ OCR

Local default: ML Kit v2 Text Recognition (script Latin, hỗ trợ tiếng Việt), chạy on-device. Trả text + geometry; **không đảm bảo table cell structure**. ML Kit bundled tránh tải mô hình lúc chạy, APK tăng dung lượng; unbundled giảm APK nhưng phải chuẩn bị download model.

Cloud option: Document AI/Layout APIs trả table structure đối với input hỗ trợ; nhưng vẫn có lỗi OCR, hạn mức/trả phí, yêu cầu internet và vấn đề chuyển dữ liệu cho bên thứ ba. Dùng backend proxy có quota/budget/expiry/auth; KHÔNG nhúng cloud secret trong APK.

8.2. OCR workflow

1. Chọn ảnh → rotate EXIF/crop/perspective/deskew/contrast (giữ original bất biến). 2. OCR text blocks. 3. Tái dựng bảng: line grouping Y; tìm cột bằng geometry + table borders + grid consistency; xử lý merged cell bằng flag uncertainty. 4. Preview editable grid đối chiếu overlay ảnh. 5. Manual confirmation. 6. Infer datatype / mapping; không cho OCR bỏ qua xác nhận ở field khóa hoặc số tiền. 7. Compare và annotate source reference `image/page/polygon`.

8.3. Giới hạn kỹ thuật không được che giấu

- Ảnh không chứa workbook metadata, công thức chưa hiển thị, font structural internals, hidden sheet/row, original logical type.
- ML Kit không tự xác định merged cells/headers; bảng nghiêng/chồng lớp/không lưới có thể không phục hồi được.
- OCR probability/confidence: không phải provider nào cũng trả confidence per cell; không được lấy `confidence=1` làm mặc định.
- Không tự đưa OCR text qua AI cloud nếu chưa có opt-in và minh bạch nơi lưu trú dữ liệu.

8.4. Metrics OCR

- `CER/WER` kiểm thử nhận dạng ký tự/từ; `cell_exact_accuracy` sau reconstruction; `table_structure_F1` khi có ground truth bounding boxes; `critical_field_error_rate` cho key/money/date; `manual_review_time`; `end_to_end_difference_precision_recall`.
- Bộ kiểm thử tối thiểu đề xuất: nhiều loại ảnh, ánh sáng, lóa, độ nghiêng, số lượng cột, tiếng Việt, ngày/số, merged cells; giá trị chấp nhận phải suy ra từ pilot không tự tuyên bố trước.

8.5. API contract cloud optional

`POST /v1/ocr/jobs` nhận ảnh encrypted transit, metadata consent/idempotency; trả `job_id` và TTL. `GET /v1/ocr/jobs/{id}` trả PENDING/PROCESSING/REVIEW_REQUIRED/FAILED, token coords, table geometry, result schema. `DELETE /v1/ocr/jobs/{id}` xóa nội dung theo retention. Hạn mức per-user + max page/byte + backoff, timeout, circuit breaker, tenant isolation. Không cung cấp chức năng này trong offline-only build.

09. NFR, hiệu năng, reliability, accessibility

9.1. NFR catalogue

ID	Tiêu chí	Mục tiêu ban đầu để thử nghiệm, không phải đo đạt
NFR-PERF-01	Preview file vừa	Hiển thị preview đầu tiên ≤ 3s cho corpus nhỏ trên thiết bị benchmark
NFR-PERF-02	So sánh 50.000 record × 15 cột	Không OOM, có progress/cancel; latency xác định sau benchmark
NFR-PERF-03	Memory	Không vượt ngưỡng heap cho thiết bị 4GB/6GB RAM đã chọn; streaming
NFR-REL-01	Crash-free	≥ 99.5% phiên theo telemetry được đồng ý, sau pilot
NFR-REL-02	Cancel	Không tạo report hoàn tất một phần; cleanup temp idempotent
NFR-SEC-01	Source immutability	0 write operations to original URIs
NFR-SEC-02	Information disclosure	Không raw cell data trong logs, crash, cloud mặc định
NFR-COR-01	Determinism	Input hashes + engine/policy version giống → report semantic giống
NFR-COR-02	Explainability	100% semantic equivalence có rule trace
NFR-UX-01	Accessibility	font scaling, screen readers, contrast, non-color indicators
NFR-OPS-01	Offline	core comparison chạy airplane mode

9.2. Các ràng buộc Android

- minSdk/targetSdk chốt khi build sau kiểm tra chính sách Play và thư viện; không tự đoán tại thời điểm đặc tả.
- Android lifecycle: process death, low-memory, SAF URI permission revoked; tác vụ dài phải có checkpoint/resume hoặc restart an toàn, foreground processing only nếu Android requirements phù hợp.
- Job design theo scope: synchronous lightweight preview; long comparison scheduled/cancellable, status persisted; hạn chế giữ bitmaps/workbook trong heap.
- Grid ảo hóa + pagination result query tránh render hàng triệu ô trong Compose.

9.3. Resource guardrails do nhóm đặt rồi benchmark

- Giới hạn kích thước file theo tier thiết bị, số sheet/cell, số ZIP entries, decompressed size, số shared strings.
- Preflight estimate row/cell count; thông báo khi vượt giới hạn, gợi ý chỉ chọn sheet hoặc sampling.
- Quotas cấu hình cục bộ, không được tùy tiện tắt zip-bomb checks để đọc file ‘khó’.

9.4. Khả năng mở rộng theo platform

Core engine Kotlin/JVM không lệ thuộc UI cho desktop/server; parser cần tách đa nền tảng. Nếu dữ liệu doanh nghiệp lớn, một backend batch processor có thể triển khai sau khi xác lập privacy/compliance và chi phí vận hành, không phải giả định MVP phải dùng cloud.

10. Threat model, bảo mật và quản trị dữ liệu

10.1. Tài sản cần bảo vệ

Bảng điểm/danh sách nhân sự, mã khách hàng, dữ liệu kế toán, ảnh chụp, policy và report, phiên so sánh. Input tệp được xem là **untrusted content** ngay cả khi người dùng chọn trực tiếp.

10.2. Threat model (STRIDE rút gọn)

Rủi ro	Biện pháp
Zip bomb/OOXML oversize	giới hạn extract/entry count/compression ratio, parse streaming, fail closed
XML entity expansion/XXE	secure parser, disable external DTD/entities, no outbound references
Spreadsheet formula injection lúc export	mọi user-controlled raw text viết thành string cell và escape CSV, test bằng Excel/LibreOffice
Macro/external link execution	read-only, never run VBA/active content; no external formula resolution
Lộ file trên máy	SAF user grant, app-internal private cache, TTL, no world-readable exports
Lộ thông tin qua logs/crash	redact by design, telemetry opt-in, aggregate-only metrics
API key leak	none in APK, server-side secret manager (nếu bật cloud)
Man-in-the-middle	TLS, standard cert validation, no trust-all certificates
Cloud vendor disclosure	explicit consent, visible recipient/purpose, retention control, data minimization
Report tampering	manifest hash/signature optional; compare hash before audit
Stale cache/confusing old report	bind input sha, config revision, engine/report version
Local DB sensitive data at rest	Room is not encryption by default; assess SQLCipher/Keystore-backed protection or no raw data persistence

10.3. Privacy by design

Default không gửi file lên server; không yêu cầu danh bạ, vị trí, quyền quản lý mọi file, không thu thập raw dữ liệu cho phân tích. Xóa tệp tạm sau session hoặc thời gian ngắn được cấu hình; cho người dùng xóa toàn bộ lịch sử. Export public phải do người dùng chủ động chọn nơi lưu.

Chính sách lưu trữ baseline: Original copy tạm xóa khi hoàn tất hoặc 24 giờ nếu người dùng cần tiếp tục; parsed content và report cached lưu chỉ khi opt-in, mặc định tối thiểu; chỉ số tổng hợp có thể giữ 30 ngày. Đây là đề xuất sản phẩm, phải được thực hiện và công bố rõ, không phải một cam kết hiện có.

10.4. Security testing gates

SAST/dependency audit, SBOM, malformed workbook fuzzing, zipbomb tests, CSV injection tests, URI lifecycle tests, Android backup inspection, logs inspection, MASVS storage/platform/privacy checks, cloud key exposure tests nếu có cloud.

10.5. Tuân thủ và pháp lý

Đánh giá quy định bảo vệ dữ liệu áp dụng theo thị trường triển khai trước khi xử lý tài liệu có dữ liệu cá nhân và trước khi truyền cloud. Không tuyên bố ISO/SOC2/GDPR/VN-law compliance nếu chưa có đánh giá, bằng chứng và quy trình tương ứng.

11. Test Strategy, test cases và quality gates

11.1. Phương pháp kiểm thử

- Unit: policy parser/canonicalizer/compare state, unicode/timezone/locale, duplicate keys.
- Property-based: symmetry `compare(a,b)` tương thích đảo A/B, determinism, idempotent normalization; điều kiện tiên quyết rõ.
- Golden fixtures: cùng dataset đã biết mọi diff; so report JSON normalized bỏ timestamps.
- Metamorphic: đảo thứ tự hàng **không** thay đổi semantic results ở key-mode; đổi style **không** ảnh hưởng content result.
- Integration: adapters XLSX/CSV/JSON, file corrupt, password protected, 1900/1904 dates.
- Instrumentation: SAF, permissions, process death/restart, storage low, sharing/export.
- Performance: corpus nhiều hàng/cột/sharedStrings, timing distributions p50/p95, max RSS/heap, cold/hot run.
- Security: Excel injection, zipbomb, XML entity, fuzz corpus, malicious formulas, privacy logs.
- OCR: CER, table reconstruction, manual review workflow, same screenshot vs original.

11.2. Các test case ưu tiên

ID	Dữ liệu A	Dữ liệu B	Kỳ vọng
TC-01	8.5 numeric	'8,5' string	EQUIVALENT **nếu** locale vi-VN và decimal field
TC-02	'00123'	123 numeric	DIFFERENT khi identifier
TC-03	0	blank	DIFFERENT by default
TC-04	false boolean	'Không'	EQUIVALENT chỉ với alias configured
TC-05	'01/02/26'	'2026-02-01'	UNRESOLVED khi format date 2-digit year/locale không rõ
TC-06	100000.00	100000	EQUIVALENT nếu decimal ignores scale
TC-07	Key duplicated	two records same key	UNRESOLVED alignment, no silent first-match
TC-08	rows reordered	same rows	EXACT/EQUIVALENT no changes in key-mode
TC-09	formula `=SUM(A1:A2)`	formula `=A1+A2`	formula changed; values can match
TC-10	archive 1KB→1GB	no other	rejected with safe error
TC-11	input `=HYPERLINK(...)`	report CSV/XLSX	exported as safe text not executable formula
TC-12	OCR '85'	source '8.5'	needs review / unresolved until confirmed
TC-13	schema new column	schema old	FIELD_ADDED
TC-14	Excel 1900/1904 date serial	same date	equivalent after date-system decode
TC-15	10%	0.1	equivalent under percent policy only
TC-16	Policy changed between runs	same file hashes	different policy_digest, separate report revision

11.3. Release gates

Gate 0: parser PoC trên Android thật; Gate 1: unit coverage tập trung critical policies >= 90% branch trên core (mục tiêu nội bộ, không đại diện correctness); Gate 2: các golden fixtures đạt 100%; Gate 3: security tests critical pass; Gate 4: performance benchmark thiết bị mục tiêu; Gate 5: smoke test signed release; Gate 6: release approval và rollback test.

11.4. Dataset đánh giá

Ít nhất 3 lớp: (a) synthetic controlled, (b) open datasets không chứa PII, (c) dữ liệu thực đã ẩn danh và có quyền sử dụng. Label truth độc lập; không lấy output engine làm ground truth. Công bố confidence interval nếu đánh giá mô hình OCR/heuristics; đừng chỉ nêu 'độ chính xác 99%' thiếu mẫu số.

12. Build, CI/CD, phát hành và bảo trì

12.1. Môi trường

`dev` (mock/fixtures), `qa` (signed internal, non-production data), `prod` (release signed). Mỗi environment có applicationId suffix rõ ràng; OCR cloud feature flag off-by-default, dùng secret backend độc lập.

12.2. Pipeline đề xuất

```
PR -> Gradle format/lint -> build/test unit -> dependency+license+SAST scan -> instrumentation CI/device farm -> benchmark nightly -> signed staging APK -> UAT -> release tag -> signed AAB/APK -> staged rollout -> monitor crash/error -> rollback if necessary.
```

- Build reproducible ở mức Gradle dependency lock, artifact hash, SBOM, checksum.
- Signing key tuyệt đối không commit repo; dùng secret manager/secured signing pipeline; key rotation/backup có người chịu trách nhiệm.
- Kiểm tra target SDK policy tại thời điểm Play submit, không giữ giả định cố định từ tài liệu.
- Bản APK cho học phần có thể phát trực tiếp, Play phát hành dùng AAB theo yêu cầu store tương ứng.

12.3. Versioning & migrations

App Semantic Versioning; engine/policy/report schema có version riêng. Thay đổi cách hiểu datatype có thể là breaking semantic change dù UI version chỉ minor; migration report phải có cảnh báo và không rewrite lịch sử silently.

12.4. Rollback

Rollback APK/AAB chỉ là một phần: bản cũ có thể không đọc Room schema mới. Migration phải forward compatible hoặc rollback plan thông qua backup đã mã hóa. Android app trên store không phải lúc nào downgrade tự động được; chuẩn bị hotfix và disable cloud feature từ server nếu dùng cloud.

12.5. Monitoring/KPI dashboard

Các số đo có privacy approval: `success_rate`, `crash_free_sessions`, `time_to_preview`, `time_to_compare`, `OOM_count`, `format_failure_rate`, `unresolved_rate`, `export_failure_rate`, `OCR_review_rate`, `cloud_api_cost_per_document` (chỉ khi bật). Không đưa bảng nội dung hay full path vào dashboard.

13. Runbook vận hành, bảo trì và xử lý sự cố

13.1. Runbook thông thường

Sự cố	Triệu chứng	Xác minh	Xử lý
SAF_REVOKED	không đọc được file cũ	URI grant còn hiệu lực?	cho chọn lại; không ghi đè
PARSER_UNSUPPORTED	file nhận sai format	inspect magic/MIME	hiển thị hỗ trợ, yêu cầu export phù hợp
ZIP_BOMB_DETECTED	fail trong parser	compression/limits	cách ly/từ chối; không tắt guardrails
OOM_RISK	tiến độ chậm, crash	memory baseline, file characteristics	giảm sheet/range, streaming, cap file
DUPLICATE_KEY	nhiều dòng cùng key	xem key profile	user chọn khóa ghép/chế độ multiset
AMBIGUOUS_LOCALE	‘1,234’ parse khó	locale profile	bắt buộc xác nhận policy
OCR_LOW_QUALITY	lệch cột/cell	overlay vs original	crop/rotate/chụp lại/manual edit
DIFF_UNEXPECTED	kết quả lạ sau update	hash+policy+engine version	replay golden fixture / rollback engine logic
EXPORT_FAILED	xuất không thành công	free storage/SAF grant	retry idempotent, temp cleanup
CLOUD_COST_SPIKE	OCR tăng phí	usage dashboard	throttle/disable cloud via feature flag

13.2. Nhóm severity và response

SEV-1: lộ dữ liệu hoặc xóa nguồn; dừng phát hành/kích hoạt chế độ an toàn, điều tra, xử lý thông báo tuân thủ. SEV-2: diff sai hệ thống trên tập dữ liệu hợp lệ; rollback/hotfix, đánh dấu báo cáo bị ảnh hưởng. SEV-3: lỗi import một format ít phổ biến, workaround manual export. Các thời hạn phản ứng cần xác định theo nhân lực thực tế thay vì tùy tiện cam kết SLA 24/7.

13.3. Incident playbook

1. Triage error code + app/engine/policy version (không copy input nhạy cảm vào ticket). 2. Xin phép dùng anonymized reproduction. 3. Reproduce bằng fixtures. 4. Root cause, severity, affected versions. 5. Fix + regression tests. 6. Roll forward có versioned release note. 7. Nếu logic diff sai, đánh dấu invalid reports và hỗ trợ chạy lại.

13.4. Retention & disaster recovery

Tệp gốc giữ nguyên tại nơi người dùng chọn. Session local chỉ giữ manifest/hash/config nếu có thể; cache sensitive TTL và xóa có thể kiểm chứng. Export report là bản sao do người dùng quản lý, không thể thu hồi tự động sau khi chia sẻ. Khôi phục config từ backup có versioning; tính toán lại báo cáo khi source vẫn còn quyền truy cập.

13.5. Lịch bảo trì

Hàng tuần: dependency vulnerabilities, crash trend, parse error spikes. Hàng tháng: Android OS compatibility, SDK licensing/version checks, golden fixtures. Mỗi release: signing, schema migration, performance, privacy review. Khi đổi OCR API: cập nhật model/version và chạy lại đánh giá corpus.

14. Lộ trình, nhân sự, chi phí và risk register

14.1. Lộ trình theo exit criteria (tham khảo nhóm 1-2 người, không phải lịch cam kết)

Sprint	Phạm vi	Exit criteria
0 (1 tuần)	spike POI/OOXML/CSV/JSON trên Android, dataset	quyết định adapter dựa bằng chứng PoC
1 (1-2 tuần)	UI import/preview, canonical data contracts	import 2 nguồn, golden sample đúng
2 (2 tuần)	mapping/key/matcher/canonicalization	core test matrix pass
3 (1-2 tuần)	result detail, export, report manifest	replay deterministic, export safe
4 (1-2 tuần)	error handling, file guardrails, retention, benchmark	no critical failures in defined corpus
5 (1-2 tuần)	OCR local + manual review optional	OCR evaluation and clear limitation
6 (tùy)	additional file adapters + cloud OCR	riêng security/cost gates

14.2. Chi phí nền tảng

Mục	Offline MVP	Cloud extension
Android Studio/Kotlin/Compose/Room	0 license fee	0 license fee
Phần mềm OCR ML Kit bundled	không có phí theo request	0 khi dùng local
GitHub-hosted CI	phụ thuộc hạn mức plan, không giả định luôn miễn phí	tương tự
Backend/cloud OCR	không cần	usage based + hosting + logging + egress
QA thiết bị	dùng thiết bị có sẵn, opportunity cost	thêm device matrix
Phát hành store	phí tài khoản/phân phối tùy kênh	tương tự

TCO: `development hours × internal rate + testing/device cost + CI/build + API calls × unit cost + storage + support + security/compliance`. Không gộp chi phí lao động thành 0 chỉ vì sinh viên tự làm. Thiết lập budget alert nếu kích hoạt cloud OCR; giá thực tế phải xác nhận tại lúc triển khai và theo region.

14.3. Risk register

ID	Rủi ro	Probability / Impact (ước lượng)	Mitigation
R-01	POI Android incompatibility	High / High	spike, fallback OOXML parser/event
R-02	false semantic equivalence	Medium / Critical	field policy, ambiguous unresolved, gold tests
R-03	large workbook OOM	High / High	streaming, page/chunk, quota
R-04	OCR bad table structure	High / High	manual verification, data-quality gates
R-05	XLSM active content/CSV injection	Medium / Critical	no macro execution, escape output
R-06	exposing PII to cloud/log	Medium / Critical	local default, consent, minimum telemetry
R-07	key duplicates/missing	High / Medium	profile, block auto-match
R-08	unsupported formats overpromised	High / High	capability levels, explicit phase gates
R-09	rule drift after updates	Medium / High	versioned manifest and golden corpus
R-10	lack of ownership/maintenance	Medium / High	named roles, runbook, release cadence

14.4. RACI gợi ý

Product owner/giảng viên chốt yêu cầu và policy nghiệp vụ; Android developer chịu UI/integration; data engineer chịu canonical model và matching; QA reviewer xác định gold truth; security reviewer phê duyệt cloud/retention trước go-live. Nếu một người kiêm nhiều vai trò, vẫn cần kiểm tra chéo độc lập cho kết luận dữ liệu quan trọng.

15. Architecture Decision Records và vấn đề còn mở

ADR-001: Offline-first core

Status: Proposed/Accepted for design baseline. **Context:** Dữ liệu bảng có thể nhạy cảm, sinh viên muốn tránh chi phí API, cần offline. **Decision:** so sánh và normalize local; cloud không bắt buộc. **Trade-off:** performance/format limits theo thiết bị, thiếu remote management.

ADR-002: Canonical Table Model thay vì so sánh Excel raw trực tiếp

Decision: mọi adapter trả `Table + Field + Row + Cell + Provenance`, nguồn excel giữ metadata cụ thể trong extension. **Consequence:** dễ hỗ trợ CSV/JSON/OCR; phải nêu rõ mất tính năng đặc thù Excel khi nguồn không chứa chúng.

ADR-003: Policy-based semantic equivalence

Decision: không ép kiểu toàn cục; chỉ normalize qua field policy; ambiguous unresolved. **Consequence:** nhiều bước UI hơn, đổi lại audit được.

ADR-004: File adapters là plugin nội bộ

Decision: version capability per adapter, read-only. XLS/XLSB/ODS/PDF chưa được ghi 'supported' trước khi test. **Consequence:** có thể triển khai từng pha không làm hỏng core.

ADR-005: OCR là nguồn không đáng tin cậy cho bảng

Decision: manual confirm before compare, retain polygon provenance; on-device primary, cloud opt-in. **Consequence:** không so formula/meta từ ảnh, không hứa tự động 100%.

ADR-006: Không ghi lại file nguồn

Decision: treat source immutable, export artifact mới qua SAF. **Consequence:** tránh mất dữ liệu và đơn giản hóa rollback.

ADR-007: Tách same-value khỏi same-formula

Decision: formula-level compare là mode riêng với cached/evaluated caveat. **Consequence:** giống số nhưng khác logic vẫn hiển thị.

ADR-008: Không coi bản thiết kế là chứng cứ đã QA production

Decision: mọi chỉ tiêu latency/accuracy phải có measurement report khi nghiệm thu; số ở tài liệu là targets. **Consequence:** giảm claims thiếu dữ kiện.

Câu hỏi cần quyết định trước production

1. Mục tiêu khách hàng chính (học phần vs người dùng doanh nghiệp) là ai? 2. Thiết bị thấp nhất và giới hạn file lớn nhất? 3. Dữ liệu có thông tin cá nhân nhạy cảm hay không? 4. Định nghĩa 'giống nhau' theo mode mặc định? 5. Kịch bản xls/xlsb/ods bắt buộc hay chỉ mở rộng? 6. Có cần backend multiuser, audit immutable log, SSO không? 7. OCR có bắt buộc cloud hoặc được phép gửi dữ liệu không? 8. Báo cáo tương đương cần pháp lý/kiểm toán cấp nào? 9. Có yêu cầu giữ lịch sử nhiều năm hay chỉ local temporary? 10. Ai sở hữu quy tắc semantic và approval khi cập nhật?

16. Nguồn kỹ thuật, thuật ngữ, giới hạn xác minh

16.1. Nguồn tài liệu kỹ thuật chính thức (kiểm tra ngày 22/10/2026)

[R1] Android App architecture recommendations, https://developer.android.com/topic/architecture/recommendations . Separation of concerns, UI/data/domain layers, coroutines, Compose, testing.

[R2] Android Storage Access Framework, https://developer.android.com/guide/topics/providers/document-provider . User-selected document access and persistable URI permissions.

[R3] Apache POI HSSF/XSSF/SXSSF overview, https://poi.apache.org/components/spreadsheet/ . Event reader và memory trade-off.

[R4] Apache POI limitations, https://poi.apache.org/components/spreadsheet/limitations.html . Giới hạn workbook và bộ nhớ.

[R5] Apache POI configuration / ZipSecureFile, https://poi.apache.org/components/configuration.html . Zipbomb guardrails.

[R6] Apache Tika supported formats, https://tika.apache.org/docs/4.0.x/formats.html . OOXML, ODF, legacy Office extraction background; không suy ra Android compatibility từ đây.

[R7] Google ML Kit Text Recognition Android, https://developers.google.com/ml-kit/vision/text-recognition/v2/android . OCR models và dependencies.

[R8] ML Kit supported languages, https://developers.google.com/ml-kit/vision/text-recognition/v2/languages . Tiếng Việt Latin.

[R9] Microsoft Azure Document Intelligence Layout, https://learn.microsoft.com/azure/ai-services/document-intelligence/prebuilt/layout . Table extraction, file and size constraints.

[R10] Google Document AI Layout Parser, https://docs.cloud.google.com/document-ai/docs/layout-parse-chunk . Layout and supported formats; cloud feature is optional.

[R11] OWASP MASVS, https://mas.owasp.org/MASVS/ . Security controls for mobile apps.

[R12] OWASP CSV injection, https://owasp.org/www-community/attacks/CSV_Injection . Protection of spreadsheet export.

[R13] Room migrations, https://developer.android.com/training/data-storage/room/migrating-db-versions . Schema/migration tests.

[R14] RFC 4180, https://www.rfc-editor.org/rfc/rfc4180 . CSV formats / MIME type.

16.2. Thuật ngữ

`Workbook`: tệp bảng tính; `Worksheet`: sheet; `Schema`: cột và các thuộc tính; `Field`: trường/cột logic; `Record`: bản ghi/hàng logic; `Physical dtype`: kiểu lưu trữ; `Semantic dtype`: loại ý nghĩa nghiệp vụ; `Canonicalization`: quy về biểu diễn có quy tắc; `Provenance`: truy nguồn chính xác; `Unresolved`: không đủ căn cứ để kết luận; `OCR`: nhận dạng chữ trong ảnh; `Layout parsing`: xác định cấu trúc tài liệu; `PoC`: thử nghiệm khả thi kỹ thuật; `SLO`: mục tiêu mức độ dịch vụ; `RACI`: phân vai chịu trách nhiệm/phê duyệt/tham vấn/nhận tin.

16.3. Căn cứ và giả định

Nguồn ban đầu là yêu cầu đề tài số 3 do người dùng cung cấp: so sánh hai file Excel, thống kê giống/khác, chỉ rõ sai khác, đọc ảnh chụp, đóng gói file cài đặt. Các chức năng mở rộng dtype, chuẩn hóa ngữ nghĩa, kiến trúc và vận hành là **đề xuất thiết kế của tài liệu này**, không phải yêu cầu đã được khách hàng/giảng viên duyệt. Không phải tất cả công nghệ đề cập đã được POC, đo hiệu năng, xác nhận giá dịch vụ hay tích hợp thực tế.